

Capítulo 9. Inferencia estadística

Inferencia: construir un modelo sobre la base de datos experimentales y extraer conclusiones

Totalidad de los resultados experimentales posibles → POBLACIÓN

Conjunto de datos que se obtiene al realizar el experimento una cierta cantidad de veces → MUESTRA

Muestra → estudiar

Población

Extraer información de las muestras para estudiar la población de las cuales se obtuvieron dichas muestras

Concepto de Muestra

Variable aleatoria X , definida sobre (Ω, \mathcal{A}, P) ,

con distribución $F_X(x) = P(X \leq x)$

que se desconoce (al menos parcialmente)

Si tenemos un EA relacionado con la VA X → X → "Observable" del experimento aleatorio

Quiero saber como se comporta la } Es decir la
POBLACIÓN } distribución de X

Muestra aleatoria Sucesión de V.A.

x_1, x_2, x_3, \dots todas iid a X .

Tendremos que

$$F_{x_1, \dots, x_n}(x_1, \dots, x_n) = P(x_1 \leq x_1, \dots, x_n \leq x_n) = \prod_{i=1}^n F_X(x_i), \forall n \in \mathbb{N}$$

⊗ X representa una magnitud física que se puede medir, mundo real y más el experimento, los valores de X van a constituir la población sujeta a estudiar

Répeticiones del EA

Notación

$\underline{X} = (X_1, \dots, X_n)$ muestra aleatoria de tamaño n con $X_1, \dots, X_n \stackrel{iid}{\sim} X$, con $F_X(x)$ ("Observables")

$\underline{x} = (x_1, \dots, x_n)$ n observaciones obtenidas al realizar n repeticiones independientes de tamaño n muestra de tamaño n (Observada)

dato población
con distribución

$$F_X(x)$$

Modelos Paramétricos

La distribución de X pertenece a una familia de distribuciones \mathcal{F} que dependen de un parámetro desconocido.

$$\Theta \text{ (íton)}$$

Familia paramétrica de distribuciones:

$\mathcal{F} = \{F_\theta(x) : \theta \in \Theta\}$ será una familia de distribuciones de probabilidad parametrizada por un subconjunto no vacío $\Theta \subseteq \mathbb{R}^P$ llamado espacio paramétrico.

Correspondencia uno a uno.

$$F_{\theta_1}(x) \neq F_{\theta_2}(x) \text{ si } \theta_1 \neq \theta_2$$

(muy) a X , queremos saber Θ

Algunos ejemplos de familias paramétricas:

$$X \sim \text{Ber}(\rho) \rightarrow f_\rho(x) = \rho^x (1-\rho)^{1-x}, \quad 0 < \rho < 1.$$

$$\rho \in \mathbb{N} = (0,1)$$

$$T \sim \mathcal{E}(\lambda) \rightarrow f_\lambda(t) = \lambda e^{-\lambda t}, \quad \lambda > 0$$

Ahora son funciones del parámetro,
los llamamos $f_\theta(x)$

$$Y \sim \mathcal{N}(\mu, \sigma^2) \rightarrow f_{\mu, \sigma^2}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad \mu \in \mathbb{R}, \quad \sigma^2 > 0$$

y tantas otras más.

Θ es un vector de 2 dimensiones

Funcióñ de Verosimilitud

es la función conjunta (de densidad o probabilidad) vista como función del parámetro desconocido Θ

$$L(\Theta) = \prod_{i=1}^n f_\Theta(x_i) \quad \text{si } X \text{ es continuo}$$

$$L(\Theta) = \prod_{i=1}^n p_\Theta(x_i) \quad \text{si } X \text{ es discreto}$$

(L por likelihood)

Notar que $L(\Theta)$ es la función de densidad/probabilidad conjunta solo que escribimos $L(\Theta)$ para decir que los X ya los conocemos, no sabemos constantes, tenemos que descubrir quién es Θ

Diremos que una familia paramétrica es **Regular** si:

1. El soporte de $f_\theta(x)$ no depende de θ
2. $f_\theta(x)$ es derivable con respecto a $\theta \forall x$
3. El conjunto paramétrico $\Theta \subset \mathbb{R}^k$ es abierto

Ejemplo: La dist. $\mathcal{E}(\lambda)$ pertenece a una familia exponencial, la $\mathcal{U}(0, \theta)$ no (θ está en el soporte)

Una más...

Familias exponenciales

Se dice que una familia de distribuciones (continuas o discretas) en \mathbb{R}^q con distribución $F_\theta(x)$, $\theta \in \Theta \subset \mathbb{R}^k$ es una familia exponencial a k parámetros, si su función de densidad (o probabilidad) se puede escribir como

$$f_\theta(x) = A(\theta) \cdot e^{\sum_i c_i(\theta) r_i(x)} \cdot h(x)$$

Donde: $c_i(\theta) : \Theta \rightarrow \mathbb{R}$

$A(\theta) : \Theta \rightarrow \mathbb{R}^+$

$r_i(x) : \mathbb{R}^q \rightarrow \mathbb{R}$

$h(x) : \mathbb{R}^q \rightarrow \mathbb{R}^+$

Ejemplo: Analicemos si pertenecen a una fña exp.

1. $X \sim \text{Ber}(\rho)$

$$\begin{aligned}f_p(x) &= \rho^x (1-\rho)^{1-x} \quad \{x \in \{0,1\}\} \\&= (1-\rho) \cdot \left(\frac{\rho}{1-\rho}\right)^x \quad \{x \in \{0,1\}\} \\&= \underbrace{(1-\rho)}_{A(\rho)} \cdot e^{\underbrace{x \ln\left(\frac{\rho}{1-\rho}\right)}_{C(\rho)}} \cdot \underbrace{\left(\frac{\rho}{1-\rho}\right)}_{h(x)}\end{aligned}$$

$$r(x) = x$$

Es fña
exponencial

Otro: $X \sim \text{Par}(z, \theta)$

$$f_\theta(x) = \frac{\theta \cdot 2^\theta}{x^{\theta+1}} \quad \{x > 2\}, \quad \theta > 2$$

$$\begin{aligned}&= \underbrace{\theta 2^\theta}_{A(\theta)} \cdot e^{-\underbrace{(\theta+1)\ln x}_{C(\theta)}} \cdot \underbrace{\frac{1}{x}}_{h(x)} \\&\quad \{x > 2\} \\&r(x) = \ln x\end{aligned}$$

Es fña
exponencial

Uno mas: $X \sim U(0, \theta)$

$$f_{\theta}(x) = \frac{1}{\theta} \mathbf{1}_{\{0 < x < \theta\}}, \theta > 0$$

↓
No puedo separar (factorizar)
a la forma de la fña
exponencial

→ No es fña exponencial

Estadísticos

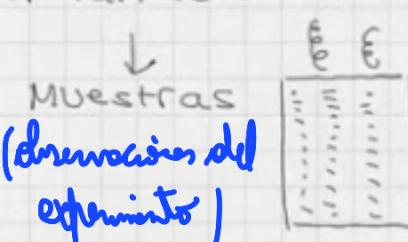
Def: Un estadístico es cualquier función
medible $T_n = T(\underline{X})$ con valores en un
espacio euclídeo de dimensión finita.

→ Dada una m.a. \underline{X} , un estadístico
es una función de la m.a. que, evaluada
en los valores observados, debe poder
resultar en un valor numérico

Obs: Esta función No puede depender
de parámetros desconocidos.

Ordenemos:

E.A. \rightarrow X Variable en estudio



Mucha información

¿Cómo la guardo?

función que le aplico a mi ME
para no tener que guardar toda
la información

Estadísticos Suficientes

Def: Sea $\underline{X} = (X_1, \dots, X_n)$ un vector aleatorio de dimensión n cuya distribución es $F_{\theta}(\underline{x})$, $\theta \in \Theta$
se dice que un estadístico $T = r(\underline{X})$ es suficiente para θ si la distribución de \underline{X} condicionada a que $T=t$ es independiente de θ , para todo t

Esto significa que si conozco a T y a la distribución de $\underline{X}|T=t$, entonces puedo reconstruir una muestra con la misma distribución que la muestra original.

Además
tengo que
guardar a T

CUIDADO Un estadístico es una función de la m.a. $\underline{X} \rightarrow$ Es una V.A.

Ejemplo. Sea X_1, \dots, X_n una m.a. de una población con distribución $Ber(p)$.

Probar que $T = \sum_{i=1}^n X_i$ es un estadístico suficiente para p .

Tenemos que $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Ber}(p)$

$T = \sum_{i=1}^n X_i$: ¿es suficiente?

Buscamos $P_{X|T=t}(x)$ y vemos que no dependa de p .

Capítulo 5!

$$P_{X|T=t}(x) = \frac{P(X=x, T=t)}{P(T=t)} = \begin{cases} 0 & \sum_{i=1}^n x_i > t \\ \frac{\prod_{i=1}^n p^{x_i} (1-p)^{n-x_i}}{(n-t)! p^t (1-p)^{n-t}} & \leq \sum_{i=1}^n x_i = t \end{cases}$$

$T = \sum_{i=1}^n X_i \sim \text{Bin}(n, p)$

$$\frac{\frac{1}{(n-t)!} (1-p)^{n-t} \binom{n}{\sum_{i=1}^n x_i} p^{\sum_{i=1}^n x_i}}{(n-t)! p^t (1-p)^{n-t}} = \frac{1}{\binom{n}{t}} \quad \text{no depende de } p$$

$\rightarrow T$ es suficiente para p .

Teorema de factorización

Sea X un vector aleatorio con función de densidad (o probabilidad) conjunta $f_\theta(x)$, $\theta \in \Theta$, entonces el estadístico $T = r(X)$ es suficiente para θ si y solo si existen dos funciones h y g tales que:

$$f_\theta(x) = g(r(x), \theta) \cdot h(x)$$

Ejemplo: Usando el Teo de factorización, hallar un estadístico suficiente para θ de una población con distribución $Z(\theta, \sigma)$, basado en una m.a. de tamaño n .

Tenemos que:

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} U(0, \theta), f_{\theta}(x_i) = \frac{1}{\theta} \mathbb{1}_{\{0 < x_i < \theta\}}$$

$$\rightarrow f_{\theta}(\underline{x}) = \prod_{i=1}^n f_{\theta}(x_i) = \frac{1}{\theta^n} \cdot \underbrace{\prod_{i=1}^n \mathbb{1}_{\{0 < x_i < \theta\}}}_{\text{Cada indicadora vale } 1 \text{ o } 0}$$

- entonces $f_{\theta}(\underline{x}) \neq 0$ si todas valen 1, y

eso va a ocurrir cuando TODAS las $x_i < \theta$,

es decir, si $\max(x_1, \dots, x_n) < \theta$

$$f_{\theta}(\underline{x}) = \underbrace{\left(\frac{1}{\theta}\right)^n}_{g(\max(x_1, \dots, x_n), \theta)} \cdot \underbrace{\mathbb{1}_{\{\max(x_1, \dots, x_n) < \theta\}}}_{\mathbb{1}_{\{\min(x_1, \dots, x_n) > 0\}}} \cdot h(\underline{x})$$

$\rightarrow T = \max(X_1, \dots, X_n)$ es suficiente para θ
¿Qué significa?

En vez de guardar todo el tipo de observaciones de X_i me guardo solo el valor más grande, voy a poder con ello generar muestras con la misma distribución que la muestra original.

¿Te acordás que hablamos de fiñas exponenciales?



Teo: Una familia exponencial a k parámetros tiene como estadístico suficiente para $\theta \in \mathbb{R}^k$ al vector $T = (r_1(x), \dots, r_k(x))$

Ahora, si X_1, \dots, X_n es una m.a. de una distribución perteneciente a una fiña exponencial a k parámetros entonces el vector aleatorio \underline{X} también tiene una distribución perteneciente a una fiña exponencial a k parámetros, y el estadístico suficiente para θ basado en esa m.a. será

$$T = \left(\sum_{i=1}^n r_1(X_i), \dots, \sum_{i=1}^n r_k(X_i) \right)$$

Ejemplo: Dada una m.a. $X_1, \dots, X_n \stackrel{\text{ iid }}{\sim} \Gamma(\alpha, \lambda)$ encontrar un estadístico suficiente para $\theta = (\alpha, \lambda)$



Para cada X_i tenemos que

$$f_\theta(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} \cdot x^{\alpha-1} \cdot e^{-\lambda x} \quad \{x > 0\}, \quad \alpha, \lambda > 0$$

$$= \frac{\lambda^\alpha}{\Gamma(\alpha)} \cdot e^{-\lambda x + (\alpha-1)\ln x} \quad \{x > 0\}$$

$$= \underbrace{\frac{\lambda^\alpha}{\Gamma(\alpha)}}_{A(\theta)} e^{-\lambda x + \alpha \ln x} \cdot \underbrace{e^{-\ln x}}_{h(x)} \quad \{x > 0\}$$

$$c_1(\theta) = -\lambda, \quad r_1(x) = x$$

$$c_2(\theta) = \alpha, \quad r_2(x) = \ln x$$

$$\rightarrow T = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n \ln X_i \right)$$

es suficiente para θ
(basado en la m.a. \underline{X})

Estimadores

- Es un estadístico cuyas valores se consideran medidas experimentales de un parámetro desconocido
- Un estimador es una función de la muestra (estadístico) que provee un valor aproximado de un parámetro o característica desconocida

Busco construir estimadores para θ
basados en la m.a. X

Ejemplo 1: $cP(\text{"salga } 1\text{"})?$ $X_i \begin{cases} 1 & \text{si sale el } 1 \\ 0 & \text{si no} \end{cases}$

$\rightarrow X \sim \text{Ber}(p)$ Quiero conocer a p

Si	No
Si	No
No	Si
No	No
:	:

$$\hat{p} = \frac{\sum_{i=1}^n X_i}{n} \quad \begin{matrix} \text{frec.} \\ \text{Relativa!} \end{matrix}$$

(el "Sombrero" significa estimador)

Ejemplo 2:



Varillas

X : Long. de las varillas

$$x_1, x_2, \dots, x_n \rightarrow \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i \quad E(X) = \mu ?$$

¿Podrá ser?

¿Cómo construyo estas funciones?