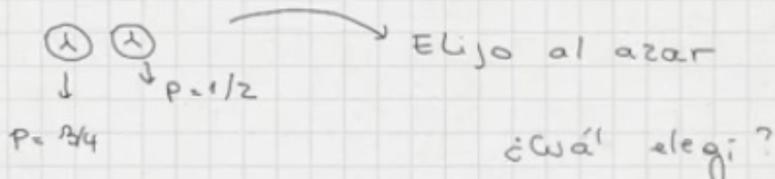


Experimento → ¿Qué puede pasar?

θ conocido → cálculo $P(X=x)$

Ahora: Conozco lo que paso...
¿θ?

Ejemplos:



Comienzo a tirar...

(Busco estimar la probabilidad
de que salga cara para saber
que moneda elegí)

P vale $\frac{3}{4}$ o $\frac{1}{2}$

En Q tiros sale cara.

$X_i = 1 \} \text{ sale cara en el tiro } i \}$

$$x_1 = 1, x_2 = 1$$

$$L(x, \theta) = P_{\theta}(x_1 = x_1, x_2 = x_2)$$

Moneda equilibrada → $L(x, 1/2) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$

Moneda cargada → $L(x, 3/4) = \frac{3}{4} \cdot \frac{3}{4} = \frac{9}{16}$

Mi estimación

para P es $3/4$

Función de Verosimilitud

Lo que observé en mis 2 tiros me muestra que doy con la moneda cargada ⇒ Elijo el parámetro que maximiza la probabilidad de los valores observados ← M étodo de máxima verosimilitud

Funciónde Verosimilitud: Me dice la probabilidad de observar la muestra en función del parámetro desconocido

Otro ejemplo.

x_i : "longitud de la varilla i"

$$x_1 \sim \mathcal{N}(45, 3)$$

$$x_2 \sim \mathcal{N}(40, 2.9)$$

$$\text{Muestra: } (x_1, x_2, x_3) = (44.2, 45.3, 48.9)$$

Con la máquina 1.

$$\begin{aligned} L(x, 45, 3) &= \prod_{i=1}^3 f(x_i) \\ &= \left(\frac{1}{\sqrt{2\pi}3} \right)^3 e^{-\frac{1}{6}(44.2-45)^2} \cdot e^{-\frac{1}{6}(45.3-45)^2} \cdot e^{-\frac{1}{6}(48.9-45)^2} \\ L(x, 40, 2.9) &= \left(\frac{1}{\sqrt{2\pi}2.9} \right)^3 e^{-\frac{1}{5.8}(44.2-40)^2} \cdot e^{-\frac{1}{5.8}(45.3-40)^2} \cdot e^{-\frac{1}{5.8}(48.9-40)^2} \end{aligned}$$

La verosimilitud es máxima en los parámetros de la máquina 1!

Método de Máxima Verosimilitud

Es un método para construir estimadores puntuales. Se basa en que, en los experimentos aleatorios, los resultados observados deben tener alta probabilidad de ocurrir

Def: Diremos que $\hat{\theta}(x)$ es un estimador de máxima verosimilitud de θ si se cumple que

$$\hat{f}_{\theta}(x) = \max_{\theta} f_{\theta}(x)$$

Es decir, buscamos el valor de θ que maximiza la función de verosimilitud

$$\hat{\theta} = \arg \max_{\theta} L(\theta)$$

Como un estimador es una función de la muestra aleatoria, será una variable aleatoria.

Método: A partir de la función de verosimilitud $L(\theta)$, busco el valor de θ que maximiza dicha función, luego $\hat{\theta} = \hat{\theta}(\underline{x})$.

Si \mathbb{W} es un subconjunto abierto tal que el soporte de $f_{\theta}(x)$ no depende de θ , como la función logaritmo es monótona creciente, maximizar $L(\theta)$ es lo mismo que maximizar $\ln(L(\theta))$. Luego, el EMV verificará $\frac{d}{d\theta} \ln(L(\theta)) = 0$

Estimadores de máxima verosimilitud

Ejemplos:

1. Hallar el EMV del parámetro p de una población con distribución de Bernoulli basado en una m.a. de tamaño n (es nuestro ejemplo del dato!!)

Fórmula

$$X_1, \dots, X_n \stackrel{iid}{\sim} \text{Ber}(p), f_p(x_i) = p^{x_i} (1-p)^{1-x_i}, p \in (0,1)$$

$$f_p(\underline{x}) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \quad \forall x_i \in \{0,1\} \quad x_i \in \{0,1\}$$

$$\rightarrow L(p) = p^{\sum x_i} (1-p)^{n - \sum x_i}, p \in (0,1)$$

Debo buscar p / $L(p)$ sea máximo.

La función de verosimilitud contempla que los x_i no son números. $L(p)$ es solo una función de p .

Es más fácil en este caso ni aplico ln

$$\ln(L(p)) = \left(\sum_{i=1}^n x_i\right) \cdot \ln p + \left(n - \sum_{i=1}^n x_i\right) \ln(1-p)$$

$$\frac{\partial}{\partial p} \ln(L(p)) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0$$

Ahora despejamos p resultando

$$p = \frac{\sum_{i=1}^n x_i}{n}$$

Si derivamos nuevamente verificamos que en p ocurre el máximo, por

eso tanto

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i \text{ es el EMV para } p$$

(es una V.A.)

2. Hallar el EMV del parámetro θ de una

Población con distribución $\mathcal{U}(0, \theta)$ basado en

una m.a. de tamaño n .

$$X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{U}(0, \theta), f_\theta(x_i) = \frac{1}{\theta} \mathbb{1}_{\{0 < x_i < \theta\}}$$

$$\rightarrow f_\theta(x) = \left(\frac{1}{\theta}\right)^n \underbrace{\prod_{i=1}^n \mathbb{1}_{\{0 < x_i < \theta\}}}_{\text{Vemos que es equivalente}}, \theta > 0$$

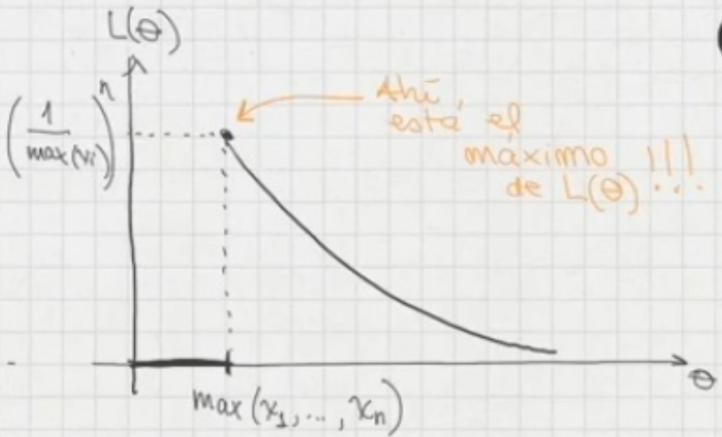
a poner

$$\mathbb{1}_{\{\max(X_1, \dots, X_n) < \theta\}} \cdot \mathbb{1}_{\{\min(X_1, \dots, X_n) > 0\}}$$

$$\rightarrow L(\theta) = \left(\frac{1}{\theta}\right)^n \mathbb{1}_{\{\max(X_1, \dots, X_n) < \theta\}}, \theta > 0$$

No puedo aplicar ln (La indicación vale 1 o 0)

→ Graficar



$$L(\theta) = \left(\frac{1}{\theta}\right)^n \mathbb{1}_{\{\max(x_1, \dots, x_n) < \theta\}}$$

→ $\hat{\theta} = \max(X_1, \dots, X_n)$ es el EMV para θ
(es una V.A.)

Uno mas (siempre los mismos 3...)

3. Hallar el EMV del parámetro θ de una población con distribución Par(2, θ) basado en una m.a. de tamaño n

$$X_1, \dots, X_n \stackrel{iid}{\sim} \text{Par}(2, \theta) \rightarrow f_{\theta}(x_i) = \frac{\theta^2}{x_i^{\theta+1}} \mathbb{1}_{\{x_i > 2\}}, \theta > 2$$

$$\rightarrow f_{\theta}(x) = \theta^n 2^{n\theta} \left(\prod_{i=1}^n x_i\right)^{\theta+1} \mathbb{1}_{\{x_i > 2\}}$$

$$L(\theta) = \theta^n 2^{n\theta} \left(\prod_{i=1}^n x_i\right)^{\theta+1}, \theta > 2$$

Más fácil si primero aplico \ln ...

$$\ln(L(\theta)) = n \ln(\theta) + n\theta \ln(2) + (\theta+1) \sum_{i=1}^n \ln(x_i)$$

Ahora derivo

$$\frac{\partial \ln(L(\theta))}{\partial \theta} = \frac{n}{\theta} + n \ln(z) - \sum_{i=1}^n \ln(x_i) = 0$$

$$\Rightarrow \frac{n}{\theta} = \underbrace{\sum_{i=1}^n \ln(x_i)}_{\sum_{i=1}^n \ln\left(\frac{x_i}{z}\right)} - \underbrace{\sum_{i=1}^n \ln(z)}$$

$\rightarrow \hat{\theta} = \frac{n}{\sum_{i=1}^n \ln\left(\frac{x_i}{z}\right)}$ es el EMV para θ (es una V.A.)

Método de MV $\longrightarrow \hat{\theta}(x)$: Estimador de θ (V.A.)

Dados $x_1, \dots, x_n \longrightarrow \hat{\theta}(x)$ ↴
 (valores observados) Estimación puntual de θ
 ↓
 número

¿Y si quiero un estimador para $g(\theta)$?

función del parámetro desconocido

Principio de invariancia

Supongamos que $\lambda = q(\theta)$ es una función biunívoca de θ . Si $\hat{\theta}$ es el EMV de θ entonces $\hat{\lambda} = q(\hat{\theta})$ será el EMV de λ .

Ejemplo: Sea $X \sim \text{Par}(2, \theta)$. Hallar el EMV de $\lambda = P(X > 3)$ basado en una m.a. de tamaño n de una población con la misma distribución de X .

Sabemos que $P(X > 3) = \left(\frac{2}{3}\right)^{\theta}$ (Tabla Supervivencia o la cuenta).

Por principio de invarianza:

$$\lambda = P(X > 3) = \left(\frac{2}{3}\right)^{\theta}$$
$$\rightarrow \hat{\lambda} = \left(\frac{2}{3}\right)^{\hat{\theta}} = \left(\frac{2}{3}\right)^n / \sum_{i=1}^n \ln\left(\frac{x_i}{2}\right) \text{ será el EMV de } \lambda$$

Ahora sólo falta que me den las observaciones x_i para encontrar estimación para λ .

Bondad de los estimadores



Dada $X_1, \dots, X_n \stackrel{iid}{\sim} F_\theta(x)$, $\theta \in \mathbb{H}$ una m.a.

Estimamos θ por $\hat{\theta}$. El Riesgo de estimar
a θ con $\hat{\theta}$ se mide con el error cuadrático
medio

$$R(\theta, \hat{\theta}) = ECM(\hat{\theta}) = E[(\theta - \hat{\theta})^2]$$

Diremos que un estimador óptimo para θ
será $\hat{\theta}^*$ tal que

$$ECM(\hat{\theta}^*) \leq ECM(\hat{\theta}), \forall \hat{\theta}$$

Se dice que un estimador es **insesgado**
para θ si

$$E_\theta(\hat{\theta}) = \theta, \forall \theta \in \mathbb{H}$$

En caso contrario, diremos que el estimador
es sesgado, y definimos su sesgo como

$$B(\hat{\theta}) = E_\theta(\hat{\theta}) - \theta$$

Propiedad. Dado un estimador de θ , se tiene
que

$$ECM(\hat{\theta}) = Var_\theta(\hat{\theta}) + B(\hat{\theta})^2$$

Obs. Si $B=0$ entonces $ECM(\hat{\theta}) = Var_\theta(\hat{\theta})$

Analicemos que pasa en nuestros 3 ejemplos.

3. $X_1, \dots, X_n \stackrel{iid}{\sim} Ber(p)$, $\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$

¿Es \hat{p} un estimador insesgado para p ?

$$E_p(\hat{p}) = E_p\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \underset{\text{Linealidad}}{=} \frac{1}{n} \sum_{i=1}^n E_p(X_i) = \frac{1}{n} \cdot n p = p$$

→ es insesgado!!

(Y si se te ocurre otro, puedes
verificar qué es mejor
calculando el
ECM)

2. $X_1, \dots, X_n \stackrel{iid}{\sim} U(0, \theta)$, $\hat{\theta} = \max(X_1, \dots, X_n)$

Para analizar si $\hat{\theta}$ es insesgado para θ , necesitamos
la distribución de $\hat{\theta}$ (capítulo 4! Lo vamos
a usar TODO el tiempo)

$$\hat{\theta} = \max(X_1, \dots, X_n)$$

$$F_{\hat{\theta}}(t) = P(\hat{\theta} \leq t) = P(X_1 \leq t, X_2 \leq t, \dots, X_n \leq t)$$

$$\underset{\text{m.a.}}{=} P(X_1 \leq t) \cdot \dots \cdot P(X_n \leq t)$$

$$= \begin{cases} 0 & \text{si } t < 0 \\ \left(\frac{t}{\theta}\right)^n & \text{si } 0 \leq t < \theta \\ 1 & \text{si } t \geq \theta \end{cases}$$

$$\rightarrow f_{\hat{\theta}}(t) = \frac{d}{dt} F_{\hat{\theta}}(t) = n \left(\frac{t}{\theta}\right)^{n-1} \cdot \frac{1}{\theta} \quad \{0 < t < \theta\}$$

Ahora si, θ

$$E(\hat{\theta}) = \int_0^\theta t \cdot \frac{n}{\theta^n} t^{n-1} dt = \frac{n}{\theta^n} \int_0^\theta t^n dt \\ = \frac{n}{\theta^n} \left(\frac{t^{n+1}}{n+1} \right) = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1}$$

$$\rightarrow E(\hat{\theta}) = \frac{n}{n+1} \cdot \theta \quad \text{No es insesgado...}$$

Pero

$$\text{Observemos que } \frac{n}{n+1} \theta \xrightarrow[n \rightarrow \infty]{} \theta$$

$$\rightarrow f_{\hat{\theta}}(t) = \frac{d}{dt} F_{\hat{\theta}}(t) = n \left(\frac{t}{\theta}\right)^{n-1} \cdot \frac{1}{\theta} \quad \{0 < t < \theta\}$$

Ahora si, θ

$$E(\hat{\theta}) = \int_0^\theta t \cdot \frac{n}{\theta^n} t^{n-1} dt = \frac{n}{\theta^n} \int_0^\theta t^n dt \\ = \frac{n}{\theta^n} \left(\frac{t^{n+1}}{n+1} \right) = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1}$$

$$\rightarrow E(\hat{\theta}) = \frac{n}{n+1} \cdot \theta \quad \rightarrow \hat{\theta} \text{ es asintóticamente insesgado para } \theta$$

$$\text{Observemos que } \frac{n}{n+1} \theta \xrightarrow[n \rightarrow \infty]{} \theta$$

Diremos que un estimador es asintóticamente insesgado si $\lim_{n \rightarrow \infty} E_n(\hat{\theta}) = \theta \quad \forall \theta \in \mathbb{H}$

$$3. X_1, \dots, X_n \stackrel{iid}{\sim} \text{Par}(2, \theta), \quad \hat{\theta} = \frac{n}{\sum_{i=1}^n \ln\left(\frac{X_i}{2}\right)}$$

Para ver si es insesgado debemos calcular $E(\hat{\theta})$, pero es muy difícil sin desarrollar un poco más.

No aplica el estadístico

$$T_i = \ln\left(\frac{X_i}{2}\right), \quad f_X(x) = 2\theta^{-2} x^{-(\theta-1)} \quad \forall x > 2$$

$$\theta > 2$$

$$\bar{F}_T(t) = P(T \leq t) = P\left(\ln\left(\frac{X}{2}\right) \leq t\right)$$

$$= \begin{cases} 0 & \text{si } t < 0 \\ P(X \leq 2e^t) & t \geq 0 \end{cases}$$

$$\rightarrow P(X \leq 2e^t) = 1 - \left(\frac{2}{2e^t}\right)^\theta \quad \text{Pareto} \quad \Rightarrow \bar{F}_T(t) = (1 - e^{-\theta t}) \mathbb{1}_{\{t \geq 0\}}$$

$$\rightarrow T \sim E(\theta)$$

$$Y = \sum_{i=1}^n T_i \rightarrow Y \sim \Gamma(n, \theta)$$

$$\rightarrow \hat{\theta} = \frac{n}{Y} \quad \text{Ahora sí calculamos la esperanza}$$

$$E(\hat{\theta}) = E\left(\frac{n}{Y}\right) = \int_{-\infty}^{\infty} \frac{n}{y} f_Y(y) dy$$

$$= n \int_0^{\infty} \frac{1}{y} \frac{\theta^n}{(n-1)!} y^{n-1} e^{-\theta y} dy$$

$$= \frac{n}{n-1} \theta \underbrace{\int_0^{\infty} \frac{\theta^{n-1}}{(n-2)!} y^{n-2} e^{-\theta y} dy}_{1}$$

$$\rightarrow E(\hat{\theta}) = \frac{n}{n-1} \theta \quad \text{No es insesgado, pero...}$$

$$Y = \sum_{i=1}^n T_i \rightarrow Y \sim \Gamma(n, \theta)$$

$\rightarrow \hat{\Theta} = \frac{n}{Y}$, Ahora si calculamos la esperanza

$$\begin{aligned} E(\hat{\Theta}) &= E\left(\frac{n}{Y}\right) = \int_{-\infty}^{\infty} \frac{n}{y} f_Y(y) dy \\ &= n \int_0^{\infty} \frac{1}{y} \frac{\theta^n}{(n-1)!} y^{n-1} e^{-\theta y} dy \\ &= \frac{n}{n-1} \theta \underbrace{\int_0^{\infty} \frac{\theta^{n-1}}{(n-2)!} y^{n-2} e^{-\theta y} dy}_{1} \end{aligned}$$

$$\rightarrow E(\hat{\Theta}) = \frac{n}{n-1} \theta \xrightarrow{n \rightarrow \infty} \theta \quad \text{es asintóticamente insesgado.}$$

Def.: Dada una sucesión de estimadores $\hat{\Theta}_n$ de

θ , decimos que $T = \hat{\Theta}$ es (debilmente)

Consistente si $\forall \epsilon > 0$

A medida que el tamaño de la muestra crece, $P_\theta(|T - \theta| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$

el estimador se acerca al valor del parámetro

Teorema: Sea una sucesión de estimadores $\hat{\Theta}_n$

de θ . Si $\text{Var}_\theta(\hat{\Theta}) \rightarrow 0$ y $E_\theta(\hat{\Theta}) \rightarrow \theta$

entonces $\hat{\Theta}_n$ es débilmente consistente

Lo demostramos usando Markov:

$$P(|X| \geq t) \leq \frac{E[h(X)]}{h(t)}$$

Si tomamos $h(y) = y^2$ y $x = \hat{\theta} - \theta$ y $\varepsilon = t$

$$P_\theta (|\hat{\theta} - \theta| > \varepsilon) \leq \frac{E_\theta[(\hat{\theta} - \theta)^2]}{\varepsilon^2} = \frac{\text{Var}(\hat{\theta}) + (\bar{E}_\theta(\hat{\theta}) - \theta)^2}{\varepsilon^2} \rightarrow 0$$

Consistencia en media Cuadrática

$$\lim_{n \rightarrow \infty} ECM(\hat{\theta}) = 0, \forall \theta \in \Theta$$

Estimadores asintóticamente normales

Se dice que $\hat{\theta}_n$ es una sucesión de estimadores asintóticamente normales si

$\sqrt{n}(\hat{\theta}_n - q(\theta))$ converge en distribución a una normal con media cero y Varianza $q'(\theta)^2 / I(\theta)$

$I(\theta)$ se llama Número de información de Fisher y se calcula como

$$I(\theta) = E \left[\left(\frac{d}{d\theta} \ln(f_\theta(x)) \right)^2 \right] = -E \left[\frac{d^2}{d\theta^2} \ln(f_\theta(x)) \right]$$

(Vale solo para familias regulares)

Convergencia en distribución \Rightarrow Calculamos la F de distribución de $\sqrt{n}(\hat{\theta}_n - q(\theta))$,

Hacemos tendencia a 0 y la distribución resultante

es una Normal

Teorema: Bajo ciertas condiciones muy generales, sea $\hat{\theta}_n(\underline{x})$ un EMV de θ consistente y sea $g(\theta)$ derivable con $g'(\theta) \neq 0 \neq \theta$, entonces $g(\hat{\theta}_n)$ es asintóticamente normal para estimar $g(\theta)$

Si $\sqrt{n} \sqrt{I(\theta)} (\hat{\theta}_n - \theta) \xrightarrow{(a)} N(0, 1)$ y $\hat{\theta}_n$ es un estimador consistente para θ (todo esto ocurrirá con los EMV), entonces vale que

$$\sqrt{n} \sqrt{I(\hat{\theta}_n)} (\hat{\theta}_n - \theta) \xrightarrow{(a)} N(0, 1)$$

Para practicar, busquemos la distribución asintótica del EMV del parámetro p de una población con distribución $Ber(p)$, basado en una m.a. de tamaño n .

$$X_1, \dots, X_n \stackrel{iid}{\sim} Ber(p) \rightarrow f_p(x) = p^x (1-p)^{1-x} \quad p \in (0, 1)$$

$$\text{el EMV de } \hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$E_p(\hat{p}) = p, \forall p \in (0, 1)$$

$$\text{Var}_p(\hat{p}) = \text{Var}_p\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{p(1-p)}{n}, \forall p \in (0, 1)$$

$\therefore \hat{p}$ es insesgado y consistente.

Busquemos $I(p)$

$$I(p) = -E\left[\frac{d^2}{dp^2} \ln(f_p(x))\right]$$

$$f_p(x) = p^x (1-p)^{1-x} \rightarrow \ln(f_p(x)) = x \ln p + (1-x) \ln(1-p)$$

$$\rightarrow \frac{\partial}{\partial p} \ln f_p(x) = \frac{x}{p} - \frac{1-x}{1-p}$$

$$\rightarrow \frac{d^2}{dp^2} \ln f_p(x) = -\frac{x}{p^2} - \frac{(1-x)}{(1-p)^2} = \frac{-x(1-p)^2 - (1-x)p^2}{p^2(1-p)^2}$$

$$\rightarrow I(p) = -E\left[\frac{-x(1-p)^2 - (1-x)p^2}{p^2(1-p)^2}\right]$$

$\xrightarrow{x \sim Ber(p)}$

$$= \frac{p(1-p)^2 + (1-p)p^2}{p^2(1-p)^2} = \frac{1-p+p}{p(1-p)} = \frac{1}{p(1-p)}$$

Si $g(p) = p$, $g'(p) = 1$, reemplazo y

listo

Tenemos que

$$\sqrt{n} (\hat{p} - p) \xrightarrow{(a)} \mathcal{N}(0, p(1-p))$$

O de forma equivalente

$$\frac{\sqrt{n} (\hat{p} - p)}{\sqrt{p(1-p)}} \xrightarrow{(a)} \mathcal{N}(0, 1)$$

que es el mismo resultado
al que llegamos si aplicamos
TCL

Algunas distribuciones importantes

Distribución Chi-Cuadrado (χ^2)

La V.A. X tiene distribución χ^2 de parámetro v (grados de libertad) si su densidad está dada por

$$f_X(x) = \frac{1}{\Gamma(v/2)} \left(\frac{1}{2}\right)^{v/2} x^{v/2-1} e^{-x/2} \quad \{x > 0\}$$

Se puede observar que coincide con una variable con distribución $\Gamma(\frac{v}{2}, \frac{1}{2})$. De ahí deducimos fácilmente que $E(X)=v$ y $\text{Var}(X)=2v$.

En el ejercicio 2.10 probamos que si $Z \sim \mathcal{N}(0,1)$, entonces $X = Z^2 \sim \chi_1^2$

Teo: Si X_1, \dots, X_n son independientes con $X_i \sim \chi_{v_i}^2$, $i=1, \dots, n$, entonces $Y = \sum_{i=1}^n X_i$ tendrá distribución χ_v^2 , con $v = \sum_{i=1}^n v_i$
(se deduce fácilmente usando propiedades de la Gamma)

Corolario: Se llama distribución χ^2 con n grados de libertad a la distribución de $U = \sum_{i=1}^n Z_i^2$ donde $Z_1, \dots, Z_n \stackrel{iid}{\sim} \mathcal{N}(0,1)$

Distribución t de Student

Sean $Z \sim \mathcal{N}(0,1)$ y $U \sim \chi_n^2$, entonces si Z y U son independientes, $T = \frac{Z}{\sqrt{U/n}} \sim t_n$



Yeso que
pinta tiene?

Distribución F de Fisher-Snedecor

Sean U y V dos variables aleatorias indep.

con distribución χ^2 de n_1 y n_2 gl. respectivamente.

Entonces $F = \frac{U/n_1}{V/n_2} \sim F_{n_1, n_2}$

TEOREMA

Sean $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$

1. $Z = \sqrt{n} \frac{(\bar{X} - \mu)}{\sigma} \sim \mathcal{N}(0, 1)$

2. $W = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2} \sim \chi^2_{n-1}$

3. W y Z son independientes

4. Si $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$, entonces

$$T = \sqrt{n} \frac{(\bar{X} - \mu)}{S} \sim t_{n-1}$$

$\bar{X} \rightarrow$ Promedio de los X