

RESUMEN ESTADISTICA

CAPITULO 9 – Inferencia estadística

Def: Inferencia

Construir un modelo sobre una base de datos experimentales y extraer conclusiones.

Def: Muestra

Variable aleatoria X , definida sobre $(\Omega, \mathcal{A}, \mathbb{P})$ con distribución $\mathcal{F}_X(x) = \mathbb{P}_{(X \leq x)}$ que se desconoce (al menos parcialmente).

$X \rightarrow$ "Observable" del experimento aleatorio

Muestra aleatoria:

X_1, X_2, \dots, X_n todas iid a X .

Muestra observada:

x_1, x_2, \dots, x_n

Con:

$$\mathcal{F}_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = \mathbb{P}_{(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)} = \prod_{i=1}^n \mathcal{F}_{X_i}(x_i)$$

Def: MODELOS PARAMETRICOS

Familia paramétrica de distribuciones:

$\mathcal{F} = \{F_\theta(x): \theta \in \Theta\}$ sera una familia de distribuciones de probabilidad parametrizadas por un espacio paramétrico Θ .

Def: FUNCION DE VEROSIMILITUD

$\mathcal{L}(\theta) = \prod_{i=1}^n f_\theta(x_i)$ si \underline{X} es continuo

$\mathcal{L}(\theta) = \prod_{i=1}^n p_\theta(x_i)$ si \underline{X} es discreto

RESUMEN ESTADISTICA

CAPITULO 9 – Inferencia estadística

Def: FAMILIA PARAMETRICA REGULAR

Una familia paramétrica es **Regular** si:

1. El soporte de $f_{\theta}(x)$ no depende de θ
 2. $f_{\theta}(x)$ es derivable con respecto a $\theta \forall x$
 3. El conjunto paramétrico $\Theta \in \mathbb{R}^p$ es abierto
-

Def: FAMILIAS EXPONENCIALES

Una familia de distribuciones es una familia exponencial si su función de densidad/probabilidad se puede escribir como:

$$f_{\theta}(x) = A_{(\theta)} \cdot e^{\sum_{i=1}^k C_i(\theta) \cdot r_i(x)} \cdot h_{(x)}$$

Donde:

$$C_i(\theta): \Theta \in \mathbb{R}$$

$$A(\theta): \Theta \in \mathbb{R}^+$$

$$r_i(x): \mathbb{R}^q \in \mathbb{R}$$

$$h(x): \mathbb{R}^q \in \mathbb{R}^+$$

Def: ESTADISTICOS

Un estadístico es cualquier función medible $T_n = T(\underline{X})$ con valores en un espacio euclídeo de dimensión finita.

Fácil: Dada una m.a. \underline{X} , un estadístico es una función de la m.a. que, evaluada en los valores observados, debe poder resultar en un valor numérico.

Obs: esta función NO puede depender de parámetros desconocidos.

RESUMEN ESTADISTICA

CAPITULO 9 – Inferencia estadística

Def: ESTADISTICOS SUFICIENTES

Un estadístico $T = r(\underline{x})$ es suficiente para θ si:

$p_{\underline{X}|T=t}(\underline{x})$ o $f_{\underline{X}|T=t}(\underline{x})$ es independiente de θ , para todo t .

Def: TEOREMA DE FACTORIZACION

Sean dos funciones h y g tales que:

$$f_{\theta}(x) = g_{(r(x), \theta)} \cdot h(x)$$

$T = r(\underline{X})$ es un estadístico suficiente de \underline{X}

Def: TEOREMA DE ESTADISTICOS PARA FLIAS EXPONENCIALES

Sean X_1, X_2, \dots, X_n una m.a. de una distribución perteneciente a una flia exponencial a k parámetros., entonces el estadístico suficiente para θ basado en la m.a. será:

$$T = \left(\sum_{i=1}^n r_1(X_i), \sum_{i=1}^n r_2(X_i), \dots, \sum_{i=1}^n r_k(X_i) \right)$$

Def: ESTIMADOR DE MAXIMA VEROSIMILITUD

A partir de $\mathcal{L}_{(\theta)}$ busco el valor de θ que maximiza dicha función.

Def: PRINCIPIO DE INVARIANZA

Suponiendo $\lambda = q(\theta)$ una función biunívoca de θ . Si $\hat{\theta}$ es el EMV de θ , entonces $\hat{\lambda} = q(\hat{\theta})$

RESUMEN ESTADISTICA

CAPITULO 9 – Inferencia estadística

Def: BONDAD DE LOS ESTIMADORES

Se mide con:

$$\mathcal{R}(\theta, \hat{\theta}) = ECM(\hat{\theta}) = \mathbb{E}[(\theta - \hat{\theta})^2] = Var_{\theta}(\hat{\theta}) + \mathfrak{B}(\hat{\theta})^2$$

Un **ESTIMADOR ÓPTIMO** para θ será $\hat{\theta}$ tal que

$$ECM(\hat{\theta}^*) \leq ECM(\hat{\theta}), \forall \theta$$

Un **ESTIMADOR INSESGADO** para θ será $\hat{\theta}$ tal que

$$\mathbb{E}_{\theta}[\hat{\theta}] = \theta, \forall \theta$$

Un **ESTIMADOR ASINTOTICAMENTE INSESGADO** para θ será $\hat{\theta}$ tal que

$$\lim_{n \rightarrow \infty} \mathbb{E}_{\theta}[\hat{\theta}] = \theta, \forall \theta$$

Con un **ESTIMADOR SESGADO** el sesgo se define como:

$$\mathfrak{B}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$$

Def: CONSISTENCIA

Dada una sucesión de estimadores $\hat{\theta}_n$ de θ , decimos que $T = \hat{\theta}$ es (débilmente) **consistente** si $\forall \mathcal{E} > 0$

$$\mathbb{P}(|T - \theta| > \mathcal{E}) \xrightarrow{n \rightarrow \infty} 0$$

Def: TEOREMA DE CONSISTENCIA

Dada una sucesión de estimadores $\hat{\theta}_n$ de θ . Si $Var_{\theta}(\hat{\theta}) \rightarrow 0$ y $\mathbb{E}_{\theta}(\hat{\theta}) \rightarrow \theta$, entonces $\hat{\theta}_n$ es débilmente consistente

Def: ESTIMADORES ASINOTITCAMENTE NORMALES

Se dice que $\hat{\theta}_n$ es una sucesión de estimadores asintóticamente normales si $\sqrt{n} \cdot (\hat{\theta}_n - q(\theta))$ converge en distribución a una normal con media cero y varianza $q'(\theta)/I(\theta)$.

$I(\theta)$ se llama al **Numero de información de Fischer** y se calcula como:

$$I(\theta) = \mathbb{E} \left[\left(\frac{d}{d\theta} \ln(f_{\theta}(X)) \right)^2 \right]$$

$$I(\theta) = -\mathbb{E} \left[\frac{d^2}{d\theta^2} \ln(f_{\theta}(X)) \right]$$

(solo para familias regulares)

Def: ESTIMADORES ASINOTITCAMENTE NORMALES

Bajo ciertas condiciones muy generales, sea $\hat{\theta}_n(\underline{X})$ un EMV de θ consistente y sea $q(\theta)$ derivable con $q'(\theta) \neq 0 \ \forall \theta$, entonces $q'(\hat{\theta}_n)$ es asintóticamente normal para estimar $q(\theta)$.

Si $\sqrt{n} \cdot \sqrt{I(\theta)} \cdot (\hat{\theta}_n - \theta) \sim^a \mathcal{N}(0,1)$ y $\hat{\theta}_n$ es un estimador consistente para θ ,

Entonces vale que:

$$\sqrt{n} \cdot \sqrt{I(\hat{\theta}_n)} \cdot (\hat{\theta}_n - \theta) \sim^a \mathcal{N}(0,1)$$

RESUMEN ESTADISTICA

CAPITULO 9 – Inferencia estadística

Def: TEOREMA CHI CUADRADO

Si X_1, X_2, \dots, X_n son iid con $X_i \sim \mathcal{X}_{\nu_i}^2$, entonces $Y = \sum_{i=1}^n X_i$ tendrá distribución \mathcal{X}_{ν}^2 , con:

$$\nu = \sum_{i=1}^n \nu_i$$

Def: COROLARIO CHI CUADRADO

Se llama distribución \mathcal{X}^2 con n grados de libertad a la distribución de

$$U = \sum_{i=1}^n Z_i^2 \text{ donde } Z_1, Z_2, \dots, Z_n \sim \mathcal{N}(0,1)$$

Def: DISTRIBUCION T DE STUDENT

Sean $Z \sim \mathcal{N}(0,1)$ y $U \sim \mathcal{X}_n^2$, entonces si Z y U son independientes:

$$T = \frac{Z}{\sqrt{U/n}} \sim t_n$$

Def: DISTRIBUCION F DE FISHER – SNEDECOR

Sean U y V v.a. indep con distribución $\mathcal{X}_{n_1}^2$ y $\mathcal{X}_{n_2}^2$ respectivamente. Entonces:

$$F = \frac{U/n_1}{V/n_2} \sim \mathcal{F}_{n_1, n_2}$$

Def: TEOREMAS

Sean $X_1, X_2, \dots, X_n \sim^{iid} \mathcal{N}(\mu, \sigma^2)$

$$1-Z = \sqrt{n} \frac{(\bar{X} - \mu)}{\sigma} \sim \mathcal{N}(0,1)$$

$$2-W = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2} \sim \chi_{n-1}^2$$

3- Z y W son independientes.

4- Si $S^2 = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{n-1}$, entonces:

$$T = \sqrt{n} \frac{(\bar{X} - \mu)}{S} \sim t_{n-1}$$